UAS

Deteksi Jenis Komentar Pengguna Twitter

Mata Kuliah: Pembelajaran Mesin

Dosen Pembimbing:

Adevian Fairuz Pratama, S.ST, M.Eng



Oleh:

TI 3E

Muhammad Lazuardi Timur 2041720114

Firgi Sotya Izzuddin 2041720207

PROGRAM STUDI D4 TEKNIK INFORMATIKA

JURUSAN TEKNOLOGI INFORMASI POLITEKNIK NEGERI MALANG

2022/2023



3 PREPOCESSING DATA

Case Folding: Konversi kalimat yang ada menjadi aturan lowercase

```
#CASE FOLDING :Pengubahan Huruf besar ke huruf kecil

def clean_lower(|wr):

| wr = \wr.lower() # mengubah menjadi lowercase text

return \wr.

# Buat kolom tambahan untuk data content yang telah dicasefolding
```

Case Folding: Menghapus karakter special seperti simbol-simbol

```
#CASE FOLDING : penghapusan karakter (@, '', "", dll)
#Remove Puncutuation
clean_spcl = re.compile('[/(){}\[\]\]@,;]')
clean_symbol = re.compile('[^0-9a-z]')
def clean_punct(text):
    text = clean_spcl.sub('', text)
    text = clean_symbol.sub('', text)
    return text
```

Case Folding: Penghapusan spasi yang berlebihan seperti enter dan lain lain

Tokenizing: Memisahkan fitur

```
Tokenizing

#tokeinze pada index ke 1

tweet=pd.DataFrame(data)
token=nttk.tokenize.WhitespaceTokenizer().tokenize(data[0])
token

"['tiffanylue',
'i',
'know',
'i',
'was',
'listenin',
'to',
'bad',
'habit',
'earlier',
'and',
'i',
'started',
'freakin',
'at',
'his',
'part']
```

Filtering:

Stemming:

4 | CLUSTERING

encoding kedalam numerik



Data Scaling

Tujuan dari data scaling ini adalah membuat data berada dalam rentang (range) yang tidak terlalu jauh. Terkadang di dalam data muncul outlier atau pencilan, yang nanti bisa menganggu dalam proses clustering. Untuk data scaling kita akan mengunakan StandardScaler, yang akan diimplementasikan terhadap data yang ada pada kolom 'sentiment' dan 'content(encode)'

K-Means Clusterring

pada bagian y_predicted, kita melakukan clustering dari persebaran data penghasilan terhadap sentiment, lalu menyimpan hasilnya di variabel y_predicted. Lalu pada bagian akhir yaitu df_columns['jenis_komentar'] = y_predicted, kita memasukkan hasil clustering yang berupa one-dimensional array ke dataframe di kolom 'jenis komentar'.

Note: nilai hasil cluster (nilai 0, 1, 2) tiap data bisa jadi berbeda dengan hasil di atas, namun setiap data masih berada dalam kelompok/kategori yang sama dengan data lainnya.



Dari cluster di atas, coba perhatikan pada sentiment yang minimal terdapat 8 orang. Pada daerah tersebut, kita bisa melihat bahwa warna merah melambangkan kelompok yang contentnya negative lebih tinggi dibanding warna hitam yang contentnya netral. Artinya tingkat content negative pada sentiment 6 lebih tinggi disbanding dengan content netral

6 LABELING



Hasil dari labelling



Memisahkan fitur dengan label

Terdapat variabel x (data source) dan y (data target) yang masing-masing menyimpan value dari kolom content dan kolom sentiment.

```
Klasifikasi dan Prediksi

# #Memisahkan Fitur dengan Label

X = df['hasil_tweet'].values

y = df['Labels_Komentar'].values
```

7 Klasifikasi, Prediksi, dan Evaluasi

```
Klasifikasi dan Prediksi

# Memisahkan Fitur dengan Label
X = df['hasil_tweet'].values
y = df['labels_komentar'].values

#EKSTRASI FITUR
#Ekstrasi Fitur yang saya gunakan adalah konsep Bag of Words dengan menggunakan fungsi TfidfVectorizer
from sklearn.nodel_selection import train_test_split
from sklearn.nodel_selection.text import TfidfVectorizer

# Split data training dan testing
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=50)

# Inisiasi TfidfVectorizer
bow = TfidfVectorizer
bow = TfidfVectorizer(stop_words='english')

# Fitting dan transform(X_train dengan TfidfVectorizer
X_train = bow.fit_transform(X_train)

# Fitting dan transform(X_train)

# Fitting dan transform(X_test)

# Klasifikasi yang digunakan adalah algoritma Random Forest
from sklearn.ensemble import RandomForestClassifier
from skl
```

```
#Klasifikasi yang digunakan adalah algoritma Random Forest
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score

#fit ke model
rdf_model = RandomForestClassifier().fit(X_train, y_train)

# Prediksi dengan data training
y_pred_train = rdf_model.predict(X_train)

# Evaluasi akurasi data training
acc_train = accuracy_score(y_train, y_pred_train)

# Prediksi dengan data training
y_pred_test = rdf_model.predict(X_test)

# Evaluasi akurasi data training
acc_test = accuracy_score(y_test, y_pred_test)

# Evaluasi akurasi data training
acc_test = accuracy_score(y_test, y_pred_test)

# Print hasil evaluasi
print(f'Hasil akurasi data train: {acc_train}')
print(f'Hasil akurasi data test: {acc_test}')

Hasil akurasi data train: 0.994875
Hasil akurasi data test: 0.444875
```

Classificationm menggunakan model algoritma Decision Tree. Pertama kita harus mengimport library yang dibutuhkan seperti, numpy (untuk melakukan perhitungan array dimensi), pandas (untuk analisis data dalam bentuk dataframe), dan DecisionTreeClassifier (untuk membuat model klasifikasi dengan Decision Tree)

DecisionTree dan juga tedapat kode program mendefinisikan variabel classifier untukproses decision tree classifier. Pada baris kode dt.fit(X_train, y_train) berfungsi membuat model DecisionTreeClassifier untuk training set.

Kemudian mendefinisikan untuk memprediksi hasil model y pred dt DecisionTreeClassifier ke test set. Setelah memprediksi hasil model. DecisionTreeClassifier ke test set, selanjutnya yaitu mengevaluasi kinerja pada set

pengujian dengan menghitung akurasi antara y test dengan y pred dt.

Dengan menggunakan function predict() kita bisa melakukan prediksi pada data test. Hasil prediksi menunjukan, model kita memiliki hasil accuracy yang kurang baik

Link Google Colabs:

https://colab.research.google.com/drive/1wNj29Fr3Aj5k6QuxF73Ph A5xoK1ylef?usp=sharing